

Detección de riesgos cardíacos en deportistas

Yanko Acuña Villaseca

Departamento de Ciencias de la Computación

Facultad de Ingeniería

Universidad de Talca

Talca, Chile

yacuna20@alumnos.utalca.cl

César Astudillo

Departamento de Ciencias de la Computación

Facultad de Ingeniería

Universidad de Talca

Talca, Chile

yacuna20@alumnos.utalca.cl

Abstract—Se busca predecir el diagnóstico general de un ECG de un deportista, identificando si es normal o de riesgo, aplicando inteligencia artificial. Para esto se entrena un modelo con la base de datos "Lobachevsky University Electrocardiography Database", y se prueba con la base de datos "Norwegian Endurance Athlete ECG Database". Esto con un enfoque en la detección de riesgos cardíacos en deportistas, buscando prevenir la muerte súbita cardíaca en deportistas de alto rendimiento.

Index Terms—diagnóstico de ECG, detección de riesgos cardíacos en deportistas, Muerte súbita cardíaca, medicina deportiva, inteligencia artificial aplicada a la medicina.

I. INTRODUCTION

La muerte súbita cardíaca es un peligro presente en los deportes de alto rendimiento, los deportistas se enfrentan a grandes esfuerzos en donde el cuerpo humano es llevado al límite. El corazón de un atleta de alto rendimiento está adaptado a sostener esfuerzos altos durante un tiempo más prolongado, estos cambios en el corazón no representan un peligro para el atleta, sin embargo, con la aparición de estos nuevos cambios, el corazón de atleta puede camuflar una miocardiopatía.

Se busca predecir el diagnóstico general de un ECG de un deportista, identificando si es normal o de riesgo, para esto se utiliza inteligencia artificial para entrenar un modelo que permita clasificar los ECGs de los deportistas. En este caso se entrena un modelo con la base de datos "Lobachevsky University Electrocardiography Database", y se prueba con la base de datos "Norwegian Endurance Athlete ECG Database", ambas bases de datos son extraídas de PhysioNet.

II. DESCRIPCIÓN DEL PROBLEMA

Los deportistas de alto rendimiento generan adaptaciones en el corazón, derivando en un corazón de atleta. Estas adaptaciones pueden ser factores de riesgo para personas no deportistas, por lo que es importante detectar estas anomalías y evaluar si corresponde a un riesgo para el deportista. Debido a que un mal diagnóstico puede derivar en una muerte cardíaca súbita.

Para solucionar este problema se plantea un modelo que busca predecir el diagnóstico general de un ECG de un deportista, se espera que **el modelo clasifique si se tiene un ECG normal o de riesgo**. Para así, alertar un posible riesgo y requerir la interpretación de un cardiólogo.

III. DESCRIPCIÓN DE LOS DATOS

Se tiene la base de datos "Norwegian Endurance Athlete ECG Database" [1] que contiene 28 ECG de 12 derivaciones de atletas de alto rendimiento de Noruega. Debido a la baja cantidad de datos se optó por expandir la cantidad de datos, para esto se usó "Lobachevsky University Electrocardiography Database" [2]. Esta base de datos contiene 200 ECG de 12 derivaciones de personas que no son necesariamente deportistas, para utilizar estos datos en un contexto de detectar anomalías en deportistas, solo se considera los datos de los pacientes hasta 45 años, por lo que finalmente se tienen 69 pacientes de la nueva base de datos.

Las bases de datos tienen diferencias entre el formato de presentación del diagnóstico, pero en ambos casos **el diagnóstico es realizado por cardiólogos**, en el caso de la BD de Atletas Noruegos el cardiólogo es especializado en medicina deportiva, además, se tiene adicionalmente un diagnóstico del algoritmo Marquette SL12. En la BD de deportistas, las etiquetas se presentan en un listado, donde primero se indica el tipo de ritmo, posterior a esto se agregan si es que existen anomalías cardíacas, y finalmente se indica el diagnóstico general del ECG, si es normal, límite o anormal. En el caso de la BD de Lobachevsky University, se indica el tipo de ritmo cardíaco, el eje eléctrico del corazón y se agregan si es que existen anomalías, en este caso no indica el diagnóstico general del ECG.

Para normalizar y estandarizar los datos de ambos ECG se hizo se normaliza los datos de los ECG ajustando los valores a un rango de 0 a 1 y luego ajusta la frecuencia de muestreo del ECG a 500 Hz. Si la frecuencia de muestreo original no es 500 Hz, realiza una interpolación para cambiar la frecuencia.

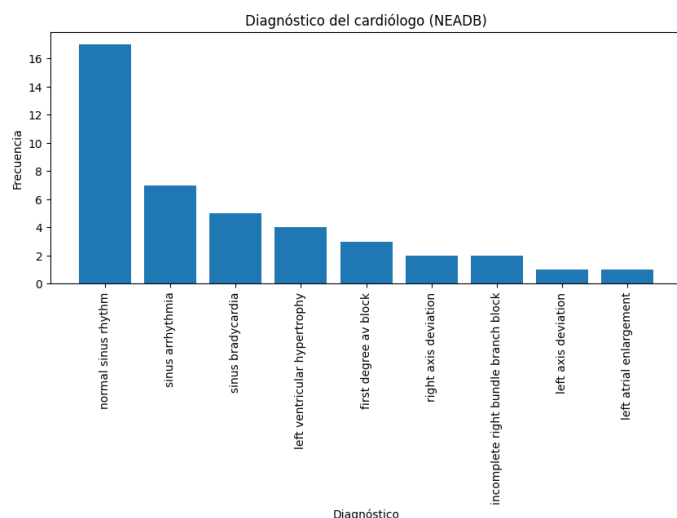


Fig. 1. Hallazgos NEADB

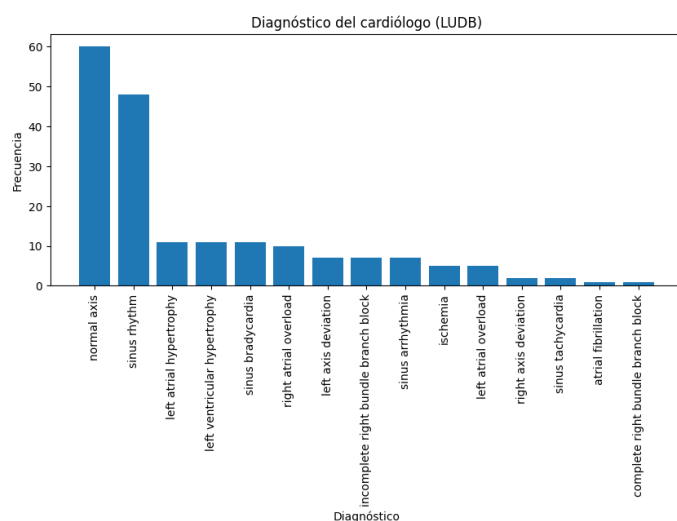


Fig. 2. Hallazgos LUDB

IV. GENERACIÓN DE DIAGNÓSTICOS DE LA NUEVA BASE DE DATOS

Debido a que falta el diagnóstico general de cada ECG de la BD de Lobachevsky University, se evaluaron las etiquetas de los hallazgos en base al “Consenso Internacional de los Criterios para la Interpretación del ECG en Atletas” [3]. Estos criterios buscan disminuir los falsos positivos mejorando la detección de anomalías que pueden derivar en una muerte cardíaca súbita.

Los hallazgos se clasifican según el riesgo que presenta una de estas anomalías hacia los deportistas. Para los datos de Lobachevsky University, se tomó en cuenta las etiquetas presentes, en donde se clasificó como de riesgo una desviación del eje eléctrico del corazón, crecimiento en el auricular derecho o izquierdo y un bloqueo completo de la rama derecha o algún tipo de isquemia.

A continuación, se presentan las tablas que clasifican los hallazgos en habituales, borderline y anormales del “Consenso Internacional de los Criterios para la Interpretación del ECG en Atletas”

Hallazgos normales en el ECG del deportista	
<i>Estas alteraciones electrocardiográficas son resultado de la adaptación fisiológica al ejercicio regular, se debe considerarlas variantes normales en deportistas y no requieren evaluación adicional en casos asintomáticos sin historia familiar significativa</i>	
Hallazgos normales en el ECG	Definición
Incremento en voltaje del QRS	Criterios de voltaje del QRS de hipertrofia ventricular izquierda aislados ($SV_1 + RV_5$ o $RV_6 > 3,5 \text{ mV}$) o derecha ($RV_1 + SV_5$ o $SV_6 > 1,1 \text{ mV}$)
Bloqueo incompleto de rama derecha	Patrón rSR' en derivación V_1 y patrón qRS en V_6 con duración del QRS $< 120 \text{ ms}$
Repolarización precoz	Elevación del punto J, elevación del segmento ST, ondas J o deflexión terminal en el QRS en las derivaciones inferiores y/o laterales
Variante de la repolarización en deportistas de raza negra	Elevación del punto J y convexa del segmento ST («cúpula») seguida de inversión de la onda T en derivaciones V_1 - V_4 en deportistas de raza negra
Patrón juvenil de onda T	Inversión de la onda T en V_1 - V_3 en deportistas menores de 16 años
Bradicardia sinusal	$\geq 30 \text{ lpm}$
Arritmia sinusal	Variación de la frecuencia cardíaca con la respiración: incrementa durante la inspiración y disminuye durante la espiración
Ritmo auricular ectópico	Las ondas P son de morfología diferente que la onda P sinusal, como ondas P negativas en derivaciones inferiores («ritmo auricular bajo»)
Ritmo de escape de la unión	La frecuencia del QRS es más rápida que el ritmo de la onda P sinusal y normalmente $< 100 \text{ x min}$ con QRS estrecho, a menos que el QRS de base sea conducido con aberrancia
Bloqueo auriculoventricular de primer grado	Intervalo PR de 200 a 400 ms
Bloqueo auriculoventricular de segundo grado Mobitz I (Wenckebach)	El intervalo PR se alarga progresivamente hasta que hay una onda P no conducida sin QRS; el primer intervalo PR después de que no haya QRS es más corto que el último PR conducido

TABLE I
HALLAZGOS HABITUALES

Hallazgos limítrofes en el ECG del deportista	
<i>Cuando aparecen aislados, probablemente no representan enfermedad cardiovascular en deportistas, pero la presencia de 2 o más requiere estudios adicionales</i>	
Anomalia en el ECG	Definición
Desviación del eje a la izquierda	-30° a -90°
Crecimiento auricular izquierdo	Prolongación de la onda P $\geq 120 \text{ ms}$ en derivaciones I o II, con porción negativa de la onda P $\geq 1 \text{ mm}$ en profundidad y $\geq 40 \text{ ms}$ de duración en V_1
Desviación del eje a la derecha	$> 120^\circ$
Crecimiento auricular derecho	Onda P $\geq 2,5 \text{ mm}$ en II, III, o aVF
Bloqueo completo de rama derecha	Patrón rSR' en V_1 y onda S $> R$ en V_6 con QRS $\geq 120 \text{ ms}$

TABLE II
HALLAZGOS BORDERLINE

Hallazgos anormales en el ECG del deportista	
<i>Estos hallazgos no están relacionados con el entrenamiento regular o la adaptación fisiológica al ejercicio, sugieren la presencia de patología cardiovascular y precisan evaluación adicional</i>	
ECG anormal	Definición
Inversión de la onda T	Profundidad ≥ 1 mm en al menos 2 derivaciones contiguas salvo las derivaciones aVR, III y V ₁
Anterior	V ₁ -V ₄ Excepción: deportistas de raza negra con elevación del punto J y elevación convexa del segmento ST seguida de IOT en V ₁ -V ₄ ; deportistas menores de 16 años con IOT en V ₁ -V ₄ , y onda T bifásica solamente en V ₃
Lateral	I y aVL, V ₅ y/o V ₆ (solamente se requiere IOT en 1 derivación, V ₅ o V ₆)
Inferolateral	II y aVF, V ₅ -V ₆ , I y aVL
Inferior	II y aVF
Depresión del segmento ST	Profundidad $\geq 0,5$ mm en al menos 2 derivaciones contiguas
Ondas Q patológicas	Relación Q/R $\geq 0,25$ o Q ≥ 40 ms en al menos 2 derivaciones (salvo III y aVR)
Bloqueo completo de rama izquierda	QRS ≥ 120 ms, complejo QRS predominantemente negativo en V ₁ (QS o rS) y R positiva mellada en I y V ₆
Trastorno de la conducción intraventricular inespecífico grave	Cualquier QRS ≥ 140 ms
Onda epsilon	Señal de baja amplitud (pequeña deflexión positiva o muesca) entre el final del QRS y el comienzo de la onda T en V ₁ -V ₃
Preexcitación ventricular	Intervalo PR < 120 ms con onda delta (empastamiento de la rama ascendente inicial del complejo QRS) y QRS ancho (≥ 120 ms)
Intervalo QT prolongado *	QTc ≥ 470 ms (varones) o ≥ 480 ms (mujeres) QTc ≥ 500 ms (marcada prolongación del QT)
Patrón de Brugada tipo I	Elevación inicial del segmento ST ≥ 2 mm con segmento descendente del ST elevado seguido de una onda T simétrica negativa en al menos 1 derivación en V ₁ -V ₃
Bradicardia sinusal grave	< 30 bpm o pausas sinusales ≥ 3 s
Bloqueo auriculoventricular de primer grado	≥ 400 ms
Bloqueo auriculoventricular de segundo grado Mobitz II	Ondas P no conducidas de forma intermitente con un PR fijo
Bloqueo auriculoventricular de tercer grado	Bloqueo completo
Taquiarritmias auriculares	Taquicardia supraventricular, fibrilación y flutter auricular
Extrasístoles ventriculares	≥ 2 extrasístoles en trazado de 10 s
Arritmias ventriculares	Dobletes, triplets y taquicardia ventricular no sostenida

TABLE III
HALLAZGOS ANORMALES

V. GRÁFICOS DE DIAGNÓSTICOS DE LOS ECG

Se presentan los diagnósticos generales de los ECG de ambas bases de datos.




Fig. 3. Diagnóstico general de NEADB




Fig. 4. Diagnóstico general de LUDB

VI. GRÁFICO PCA PARA VISUALIZAR ECG NORMALES Y DE RIESGO

Aunque no se puede diagnosticar si un ECG es de riesgo mediante este gráfico, si se logra visualizar un sesgo entre la posición de los ECG y la clasificación, debido a que hacia los bordes se encuentran los casos que se clasifican como de riesgo, y existe una zona en donde se agrupa la mayor cantidad de casos normales. Debido a que existe una diferencia de distancia entre el grupo de ECGs normales y los casos de bordes, se podría calcular la distancia de un ECG frente a los datos de entrenamiento y buscar los casos más cercanos, para así detectar los casos de riesgo.

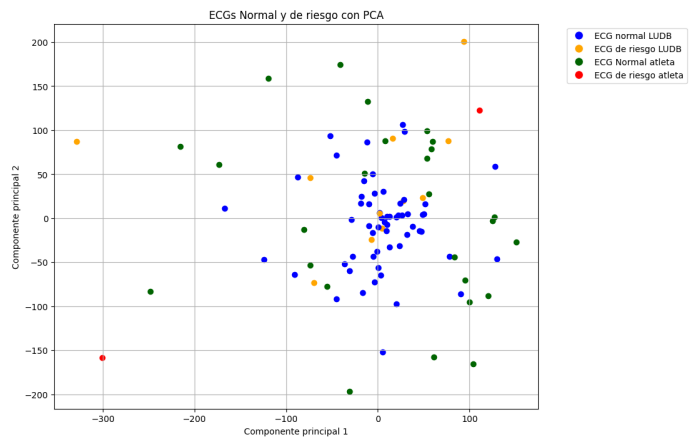


Fig. 5. Gráfico PCA

VII. USO DE LOS DATOS

Para este problema se utilizarán los datos de la BD de Lobachevsky University para entrenar el modelo, utilizando las etiquetas generadas para los diagnósticos, y se utilizará la BD de Atletas Noruegos para probar el modelo entrenado.

VIII. COMPARACIÓN DE MÉTRICAS DE DIFERENTES MODELOS DE CLASIFICACIÓN

Con el fin de usar un modelo de clasificación que se adapte a las necesidades del problema, se entrenaron diferentes modelos y se calcularon las métricas obtenidas al realizar

predicciones. Los modelos entrenados fueron los siguientes: K-nearest neighbors con Dynamic Time Warping (DTW), Decision Tree, Naive Bayes, Support vector machine (SVM) y XGBoost.

Los modelos como Decision Tree, Naive Bayes, Support vector machine (SVM) y XGBoost, fueron entrenados con los datos estadísticos de cada señal ECG.

Las métricas de exactitud, precisión, recall y f1 son las siguientes:




Fig. 6. Gráfico de comparación entre modelos

Para este caso es importante tener el mayor porcentaje de recall debido a que se deben detectar todos los casos de riesgo. Según las métricas, es posible utilizar los modelos de KNN con DTW y XGBoost. El problema de XGBoost es que, aunque no genera demasiados falsos positivos, este no clasifica correctamente los casos de riesgo.

IX. SELECCIÓN Y JUSTIFICACIÓN DE MODELOS

Para predecir el diagnóstico general de un ECG, identificando si es **normal**, o **de riesgo**, se utilizó el modelo de **K-nearest neighbors (KNN)** utilizando **Dynamic Time Warping (DTW)** como métrica de distancia, para así, comparar los ECGs y encontrar el más cercano. Se utilizó esta técnica debido a la baja cantidad de datos, lo que dificultaba aplicar técnicas que requieren un mayor volumen de datos como Random Forest o algún algoritmo de aprendizaje supervisado.

Una de las principales ventajas de utilizar DTW en el análisis de ECGs, es su capacidad para alinear y comparar señales de diferentes longitudes o con variaciones en el tiempo. Para el caso de los ECGs, esto es útil debido a las siguientes razones:

A. Manejo de Variabilidad Temporal

Los ECGs suelen tener variaciones en la frecuencia y duración de los latidos cardíacos. DTW permite alinear estas señales, ignorando las pequeñas diferencias temporales, permitiendo detectar patrones de una mejor manera.

B. Eficiencia con Pocos Datos

Al no requerir grandes volúmenes de datos para entrenamiento, DTW se adapta de manera ideal para conjuntos de datos pequeños y permite encontrar patrones relevantes.

Este modelo es relevante debido a que permite comparar las señales de ondas sin que afecten los pequeños desfases de tiempos, además al comparar señales permite comparar entre las formas de las ondas, detectando con precisión las similitudes entre las señales.

Además, al implementar diferentes modelos, se obtuvo que el modelo KNN con DTW presenta mejores métricas al realizar predicciones.

X. IMPLEMENTACIÓN Y EVALUACIÓN DE MODELOS

El modelo de K-nearest neighbors (KNN) con Dynamic Time Warping (DTW) como métrica de distancia es entrenado con la BD de Lobachevsky University, y para probar la precisión del modelo se utiliza la BD de Atletas Noruegos. La implementación de KNN con DTW consiste en que, para cada ECG de la BD de Atletas Noruegos, se calcula las distancias DTW con respecto a cada ECG del conjunto de entrenamiento. Con las distancias calculadas con respecto a todos los ECGs de entrenamiento, se buscan los k vecinos más cercanos, y el diagnóstico del ECG corresponde al grupo mayoritario de los vecinos hallados.

XI. EVALUACIÓN DE VARIANTES DE KNN

Para obtener mejores resultados se optó por modificar el algoritmo KNN, en este caso se implementó que en base a los n vecinos hallados, si alguno de estos vecinos corresponde a un ECG de riesgo, el ECG evaluado se clasifica como de riesgo. Se evaluaron los resultados de KNN con k igual a 3, 5 y 7, y con el algoritmo del grupo mayor y la variante de un vecino de riesgo.




Fig. 7. Gráfico de comparación entre modelos

Según los resultados obtenidos, se obtuvo un recall en todas las pruebas realizadas con la variante de KNN de tener un vecino de riesgo. La versión estándar de KNN con k igual

a 3, obtuvo un 100% de precisión pero no logró clasificar correctamente los casos de riesgo, lo cual, en este caso es primordial. Se optó por utilizar k igual a 3 y la versión de tener un vecino de riesgo, debido a que al aumentar el valor de k aumenta la aparición de falsos positivos.

Al evaluar el modelo, este entrega una exactitud del 85,71%, esto debido a que el modelo detecta los casos que son de riesgo, pero indica algunos falsos positivos, clasificando casos que son normales como de riesgos. Sin embargo, es importante que los casos de riesgo no sean detectados como normales.

A. Matriz de Confusión de Diagnósticos de ECGs de Atletas

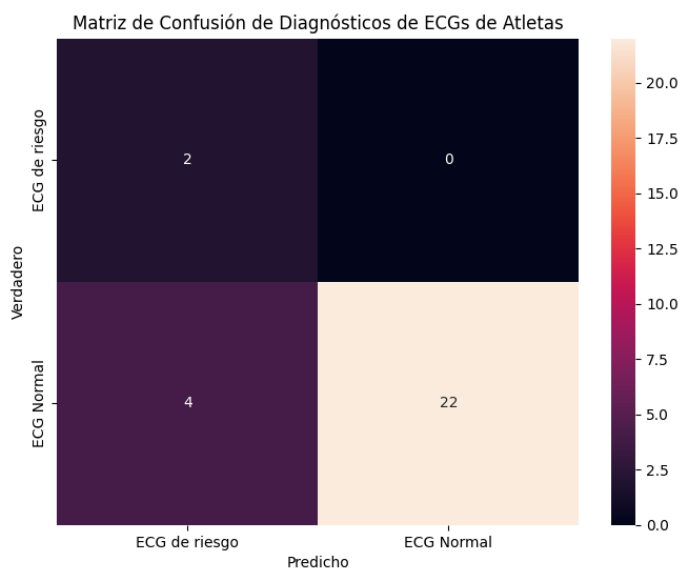


Fig. 8. Matriz de Confusión Atletas

Debido a que en este caso se generan ciertos falsos positivos, se presenta la opción de no clasificar este diagnóstico como un completo error, sino que este caso posiblemente sí necesite la evaluación de un cardiólogo. Debido a que se posee las etiquetas del algoritmo SL12, se tiene la posibilidad de usar este diagnóstico para comprobar la predicción. Es por esto que cuando el modelo predice un ECG como de riesgo y el cardiólogo no lo contempló de esta manera, se evalúa el diagnóstico del algoritmo SL12.

Al contemplar este diagnóstico adicional, se obtiene una exactitud del 96,4%, ya que el algoritmo SL12 había clasificado los ECGs que dieron falsos positivos como de riesgo. Sin embargo, el cardiólogo al realizar un análisis del paciente descartó los riesgos. Por lo que el modelo no se aleja del diagnóstico final, ya que el objetivo del modelo es indicar si existe una alerta, para que así un cardiólogo pueda diagnosticar si existe un posible riesgo para el deportista.

B. Matriz de Confusión de Diagnósticos de ECGs de Atletas usando etiqueta de SL12

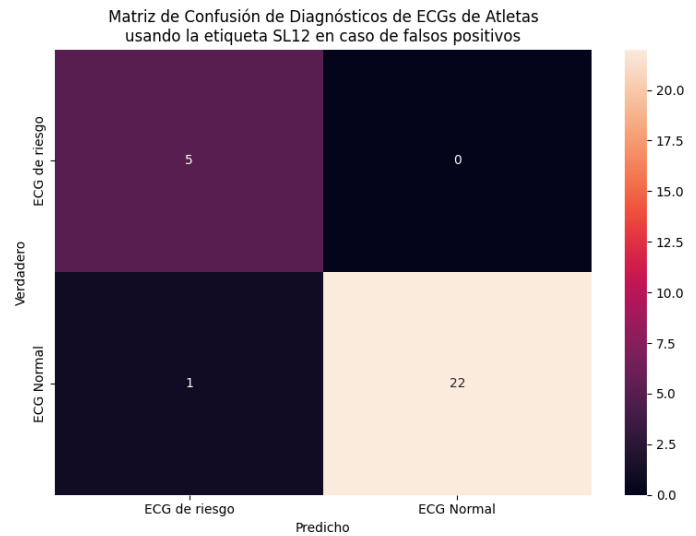


Fig. 9. Matriz de Confusión Atletas con SL12

El recall es de 100% ya que se detectaron todos los casos de riesgo correctamente, lo que es primordial para el modelo. Adicionalmente, se tiene un 33,33% de precisión, ya que se generaron algunos falsos positivos, sin embargo, este porcentaje aumenta a 83.33% si se consideran los diagnósticos del SL12. El F1 tiene un 50% considerando las etiquetas de los cardiólogos y un 90,91% considerando adicionalmente la etiqueta del SL12.

C. Métricas de la evaluación




Fig. 10. Métricas de la evaluación con DTW

XII. COMPARACIÓN DE GRÁFICO PCA CON PREDICCIONES REALIZADAS

A. Gráfico de etiquetas de cardiólogos




Fig. 11. Gráfico PCA

B. Gráfico de etiquetas de predichas por el modelo




Fig. 12. Gráfico PCA con etiquetas predichas

C. Gráfico con etiquetas de modelo y con etiquetas del SL12




Fig. 13. Gráfico PCA con etiquetas de SL12 y predicción

De los gráficos se puede analizar que los ECG detectados como de riesgo se encuentran hacia los bordes del gráfico, separados de los casos normales, estos casos se acercan más a ECGs que están clasificados como de riesgo. Sin embargo, según el cardiólogo, este corresponde a un ECG normal, lo que nos indica un posible falso positivo.

Para evaluar la veracidad de estos falsos positivos, se comprobarán las etiquetas del algoritmo SL12. Para este caso se clasifican como, un FP con riesgo en etiqueta SL12 y un FP normal en SL12.

Se tiene que los FP que tienen riesgo en la etiqueta SL12, se ubican en los bordes del gráfico, ya que estos se encuentran distanciados de la zona en donde se agrupa la gran mayoría de los ECG normales. Esto indica que estos casos de falsos positivos si presentan una diferencia frente a los casos normales, por lo que detectar estos casos es un acierto, ya que posiblemente se necesite la evaluación de un cardiólogo para descartar un caso de riesgo. El caso que se consideró de riesgo y si era normal en la etiqueta del SL12 se encuentra cercano a los ECGs normales, por lo que se tiene realmente un falso positivo.

XIII. CONCLUSIONES

Al realizar el entrenamiento del modelo KNN con DTW con la BD Lobachevsky University y las pruebas con la BD de Atletas Noruegos se obtuvieron resultados aceptables, el aspecto a destacar es que se detectaron satisfactoriamente todos los casos de riesgos. Esto es un aspecto importante, ya que es crucial no descartar ninguno de estos casos. Sin embargo, se generaron algunos falsos positivos, pero esto no es un total error, ya que como se demostró anteriormente, al contemplar el diagnóstico del algoritmo SL12, es posible que estos casos también necesitaban la evaluación de un cardiólogo para descartar los riesgos.

Analizando el gráfico PCA, se logró comprobar e identificar que existe un sesgo cuando se tiene casos de riesgo, ya que estos se alejan de la zona donde se agrupan los casos normales. Además, los casos que fueron identificados como

falsos positivos que resultaron de riesgo en la etiqueta del algoritmo SL12, se encuentran separados de la zona en donde se agrupan los casos normales, representando una división entre los casos normales y los de riesgo.

El modelo logra buenos resultados, y se entrega un diagnóstico enfocado a deportistas. Sin embargo, el algoritmo se vuelve lento al tener muchos datos, una mejora sería optimizar la implementación del DTW para que el algoritmo diagnostique en un menor tiempo.

REFERENCES

- [1] Singstad, B. (2022). Norwegian Endurance Athlete ECG Database (version 1.0.0). PhysioNet. <https://doi.org/10.13026/qpjf-gk87>.
- [2] Kalyakulina, A., Yusipov, I., Moskalenko, V., Nikolskiy, A., Kosonogov, K., Zolotykh, N., & Ivanchenko, M. (2021). Lobachevsky University Electrocardiography Database (version 1.0.1). PhysioNet. <https://doi.org/10.13026/ecgm-h675>.
- [3] Drezner JA, Sharma S, Baggish A, et al. International criteria for electrocardiographic interpretation in athletes: Consensus statement. *Br J Sports Med.* 2017;51:704-731